

Modelo predictivo para el análisis del Riesgo de Crédito

1^{er} David Crespo
Facult. Barbieri de Ingeniería
MIAA
Cali, Colombia
david.crespo@u.icesi.edu.co

2^{do} Julián Espinosa
Facult. Barbieri de Ingeniería
MIAA
Cali, Colombia
julian.espinosa1@u.icesi.edu.co

3^{ro} Jhon Cuervo
Facult. Barbieri de Ingeniería
MIAA
Cali, Colombia
jhon.cuervo@u.icesi.edu.co

I. INTRODUCCIÓN

En el área de análisis de riesgo de crédito, uno de los retos más relevantes es la correcta clasificación de clientes potenciales entre quienes probablemente cumplirán sus obligaciones crediticias (buenos) y quienes tienen un alto riesgo de impago (malos). Este proceso, aunque históricamente ha estado basado en reglas de negocio y análisis tradicionales, presenta desafíos cuando se trata de grandes volúmenes de información y múltiples fuentes como los burós de crédito. Un error en esta clasificación puede representar pérdidas financieras por mora o, en sentido contrario, pérdida de oportunidades comerciales por rechazos innecesarios. Además, áreas como originación de crédito, cobranza y comercial se ven directamente impactadas por la calidad de esta clasificación. En este entendido, la pregunta de investigación es: *Qué combinación de variables y enfoques de modelado permite construir un clasificador de riesgo de crédito para personas naturales que, con buen compromiso entre sensibilidad, especificidad y calibración, identifique oportunamente clientes con alto riesgo de incumplimiento en un horizonte de 12 meses?* El desempeño se evaluará con métricas robustas (AUC, KS, Brier score) y con énfasis en la sensibilidad de la clase de incumplimiento, por su impacto financiero y prudencial.

II. ANÁLISIS DEL PROBLEMA

II-A. Identificación del problema

Las entidades financieras que incluyen dentro del portafolio líneas de crédito de consumo a **personas naturales** requieren estimar y monitorear el riesgo de crédito a nivel cliente –producto, mejorar en los niveles de aprobación sin aumentar riesgo, reducción de mora temprana y provisiones y agilizar la originación y mejorar la experiencia del cliente [1]. En la práctica, se observan brechas:

- *Desfase temporales*: Se enfrentan amodelos que no reflejan oportunamente los cambios derivados del buen o mal hábito de pago de los clientes en diferentes elementos de deuda o cartera.
- *Clases desbalanceadas*: Que naturalmente, dada la baja incidencia de incumplimiento afecta la discriminación y calibración de los modelos.
- *Limitación en decisiones*: Se pueden presentar desajuste de las reglas de colocación, calculos del pricing y cobranza.

Luego, las entidades financieras requieren de sistemas integrados que detecten posibles clientes en incumplimiento y riesgos de manera oportuna, remita alertamientos y permita cambios en las políticas de colocación, estrategias de cobranza que impacten de manera positiva la rentabilidad, posición en el mercado y conserve la buena la calificación de la cartera.

II-B. Definiciones normativas

En este trabajo se usarán las siglas internacionales de Basilea: **PD** (Probabilidad de Incumplimiento), **LGD** (Pérdida Dada el Incumplimiento) y **EAD** (Exposición al Incumplimiento). Cuando la documentación local emplee notaciones alternativas (p. ej., PI/PDI/EDI), se entenderán como equivalentes, manteniendo la coherencia conceptual del marco de pérdida esperada.

Las definiciones normativas hacen parte de las limitaciones de las implementaciones de los modelos de riesgo crediticio, las disposiciones de la SuperFinanciera en el capítulo 31 del SIAR [2]. Las definiciones del modelo de perdida esperada son:

1. **PI (Probabilidad de incumplimiento):** probabilidad de que un cliente incurra en mora (90 días) en un horizonte 12 meses.
2. **PDI (Probabilidad dado el incumplimiento):** proporción de pérdida condicionada al incumplimiento.
3. **EDI (Exposición dado el incumplimiento):** exposición esperada al momento del incumplimiento.

II-C. Objetivo general

Diseñar un modelo predictivo del riesgo de crédito para la cartera de consumo otorgado a personas naturales que:

1. Estime **PI** con actualización periódica (12 meses).
2. Detecte y alerte tempranamente cambios poblacionales y de desempeño.
3. Habilite **acciones trazables y medibles** (ajuste de cupo, pricing, cobranza y calibración de políticas de colocación).

II-D. Árbol del problema

El árbol del problema propuesto es:

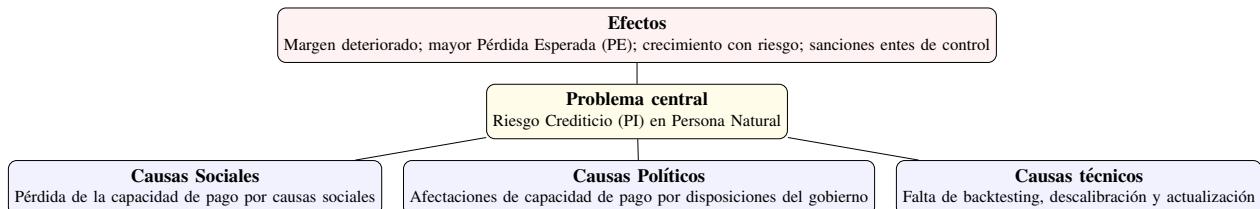


Figura 1. Árbol de problemas: causas → problema central → efectos.

III. ESTADO DEL ARTE

La posibilidad de impago es un tema que ha preocupado a los sistemas de préstamo desde antiguos sistemas de trueque hasta las sofisticadas economías de mercado de hoy. El análisis de riesgo de crédito ha evolucionado considerablemente, adaptándose a los cambios de contextos económicos, tecnológicos y regulatorios. Por tal motivo, a lo largo de la historia se han implementado diferentes reglas como penas por esclavitud en la época mesopotámica en los años 3000 AC, evaluación de la solvencia en la Edad Media y la ley de bancarrota instaurada en Inglaterra en el siglo XVI.

Para los tiempos más recientes, acompañados de una revolución industrial y auge en la actividad empresarial, el riesgo crediticio se vuelve más complejo abriendo paso a la creación de bancos que introducen nuevas formas de crédito y, por ende, nuevas formas de riesgo. La evaluación del riesgo en ese momento se realizaba en mayor medida de manera reputacional o por relaciones interpersonales.

En las últimas décadas el análisis de riesgo crediticio es un tema que ha venido evolucionando de la mano con la evolución de técnicas de análisis de datos e implementación de modelos que buscan mejorar las predicciones de impago de la población en el sistema financiero. Esto ha generado un impacto importante en las entidades financieras que han optado por estas implementaciones, dado que están obteniendo mayores utilidades al automatizar sus procesos, reducción en los tiempos de respuesta a los clientes y mayor facilidad para almacenar la información. Muchos autores han investigado y desarrollado diferentes soluciones utilizando modelos predictivos buscando mejorar la gestión del riesgo de crédito.

Cuzman (como se citó en Haro, Martínez, [3]) habla de modelos como Montecarlo o matrices de riesgo complejas para hacerle frente a los desafíos en la detección de posibles morosos agregando mayor precisión a la evaluación proporcionando una visión más detallada de la exposición al riesgo y al mismo tiempo apoyando decisiones

informadas sobre la gestión de carteras.

Otro tipo de modelos utilizados y potenciados por IA se enfocan en el uso de técnicas como redes neuronales [4] que ha demostrado un alto potencial de la detección de patrones complejos. Por ejemplo, el modelo desarrollado por Duhaidahawi en Irak [3], que no solo demostró una alta precisión en la clasificación de los clientes, sino que también ofrece retroalimentación útil para la formulación o ajuste de políticas de mitigación.

Así mismo, modelos de ensamble como LightGBM, han demostrado ser óptimos, ofreciendo un desarrollo robusto en el tratamiento de clases desbalanceadas y la utilización de varias métricas de desempeño [5].

Porras y Daniel (como se citó en Haro, Martínez [3]) mencionan la importancia de evaluar la capacidad de clasificación de un modelo de riesgo crediticio haciendo uso de curvas ROC.

En general, los modelos Logit y Probit se encuentran catalogados como los modelos de mayor uso de clasificación en riesgo de crédito. Velandia (como se citó en Castañeda, 2020 [6]) utiliza un modelo logit porque con él, captura la probabilidad de default, además reconoce las concluyentes causas de riesgo de dicha probabilidad, así como su validez para tomar decisiones más acertadas.

A modo de referencia, análisis realizados por otros autores muestran como resultados aceptables, valores en torno al 60 % en métricas del recall, lo que indica la proporción de clientes malos que rechaza el modelo. Esto se puede ver en publicaciones como “Aplicación de técnicas de Machine Learning para la predicción del riesgo de default de un cliente en una compañía de Filipinas”. Otro ejemplo es el análisis realizado por Valenzuela, M (2025) donde para un modelo de redes neuronales, encuentra como aceptable un recall cercano al 60 % y una precisión del 27 % [7]

Por lo tanto, las nuevas tecnologías han brindado unas herramientas más robustas y confiables para la clasificación de clientes buenos y malos. Sin embargo, estas metodologías se encuentran constantemente retadas por los cambios sociales, políticos, económicos y tecnológicos, que llevan en ocasiones a mantener erróneamente modelos desactualizados para la evaluación del riesgo crediticio.

Así mismo, otras técnicas exploradas para la detección de clientes incumplidos es el árbol de decisiones que representa, mediante nodos y ramas, las distintas alternativas disponibles y sus posibles consecuencias. Se construye a partir de reglas del tipo “si... entonces...”, asignando a cada resultado costos y probabilidades, lo que permite calcular y comparar el valor esperado de cada opción. En economía y finanzas, esta herramienta se utiliza para analizar problemas de riesgo e incertidumbre —como el riesgo crediticio, la evaluación de inversiones o la selección de estrategias financieras—, pues ofrece un mapa claro de los riesgos y beneficios asociados a cada decisión. Su utilidad depende de la calidad de la información disponible: cuando existe información asimétrica, los agentes mejor informados pueden obtener una ventaja al definir sus estrategias [8].

Por lo tanto, las nuevas tecnologías han brindado unas herramientas más robustas y confiables para la clasificación de clientes buenos y malos. Sin embargo, estas metodologías se encuentran constantemente retadas por los cambios sociales, políticos, económicos y tecnológicos, que llevan en ocasiones a mantener erróneamente modelos desactualizados para la evaluación del riesgo crediticio.

IV. CRONOGRAMA

El proyecto seguirá las fases del modelo ASUM-DM [9], adaptadas al contexto de nuestro problema de análisis de riesgo de crédito. Estas fases permiten estructurar el proceso de desarrollo del modelo desde la comprensión del problema hasta la implementación y optimización de los resultados. Se tiene así, el cronograma para las 5 actividades como se ve en la figura 2

Notas adicionales

- Las fechas están alineadas con el calendario del curso y la entrega final del reporte final.
- Los modelos se desarrollarán en un notebook documentado de Google Colab.
- Se mantendrá la trazabilidad mediante control de versiones en GitHub.

Fase ASUM-DM	Actividad(es) principal(es)	Entregable(s)	Duración estimada (días)	Fecha de Inicio	Fecha Fin	Responsables
1. Analyze (Analizar)	Definir el problema de riesgo de crédito, los objetivos, el árbol de problemas y las métricas de éxito.	Reporte de la primera etapa: documento PDF que contiene el análisis del problema, el estado del arte y la planeación.	23	27-sep-25	20-oct-25	David Crespo Jhon Cuervo Julián Espinosa
2. Prepare (Preparar)	Preparar, limpiar, transformar y validar el dataset German Credit, mediante un flujo unificado que combine ETL (Extracción, Transformación y Carga) con EDA (Análisis Exploratorio de los Datos).	Dataset procesado, reporte EDA y diccionario de datos.	4	21-oct-25	25-oct-25	David Crespo Jhon Cuervo Julián Espinosa
3. Model (Modelar)	Entrenar modelos de referencia, ajustar hiperparámetros y comparar las métricas.	Reporte de la segunda etapa: documento PDF que contiene Análisis Exploratorio de los Datos y modelos de referencia y experimentos. Anexo: Notebook de modelado y tabla comparativa de desempeño.	15	26-oct-25	10-nov-25	David Crespo Jhon Cuervo Julián Espinosa
4. Deploy (Desplegar)	a) Analizar desempeño de los modelos, determinar el umbral de decisión y seleccionar el modelo final. b) Elaborar el reporte final y la presentación en video.	Reporte final: documento PDF que contiene introducción, metodología, resultados, discusiones, conclusiones y referencias. Presentación corta en un video de 10 minutos resaltando los aspectos relevantes del proyecto, hallazgos y conclusiones más importantes.	17	11-nov-25	28-nov-25	David Crespo Jhon Cuervo Julián Espinosa
5. Operate & Optimize (Operar y Optimizar)	a) Implementar el modelo predictivo en un entorno funcional o de simulación. b) Elaborar la propuesta para el monitoreo y ajuste del modelo seleccionado.	Reporte de implementación: documento PDF que contiene información de la implementación, el desempeño y el uso del modelo predictivo de riesgo de crédito. Plan de Monitoreo: documento PDF con el plan para monitorear y ajustar el modelo de riesgo crediticio.	60	*	*	David Crespo Jhon Cuervo Julián Espinosa

Figura 2. Cronograma

- Las actividades de la fase 5. Operate & Optimize (Operar y Optimizar), se realizarán de acuerdo a los resultados obtenidos y testiendo con los datos históricos con el fin de determinar la viabilidad de un paso a producción pasado por área coo la curaduría de modelos e implementación operativa.

V. ANÁLISIS EXPLORATORIO DE LOS DATOS

En el análisis exploratorio se identificaron valores atípicos principalmente en `credit_amount` y, en menor medida, en `duration`. Estos reflejan la heterogeneidad propia del negocio (operaciones de alto monto y plazos extendidos). No obstante, para evitar que los extremos distorsionen el ajuste y la calibración, se considerarán transformaciones suaves (p. ej., `log1p`) o winsorización en percentiles altos, documentando su efecto sobre métricas de discriminación y calibración.

V-A. Tipos de variable y comportamientos observados

V-A1. Variables numéricas: En el Cuadro I se resume el comportamiento de las principales variables numéricas. Se observa que el monto del crédito (`credit_amount`) presenta una distribución fuertemente asimétrica a la derecha, con una concentración de créditos en valores bajos y una cola larga de operaciones de alto monto. Esta configuración sugiere la necesidad de aplicar transformaciones (por ejemplo, logarítmica) o técnicas de winsorización para mitigar el impacto de valores extremos en el ajuste del modelo.

La variable `duration` exhibe valores discretos asociados a plazos estándar (12, 24, 36, 48 meses, entre otros), lo que confirma su naturaleza ordinal. Esta propiedad favorece la definición de puntos de corte o *binning* supervisado, preservando relaciones monotónicas entre el horizonte del crédito y el riesgo observado. La edad del solicitante (`age`) presenta una distribución unimodal centrada en el rango de 30 a 40 años, con cola hacia edades mayores; este patrón invita a comprobar posibles efectos no lineales (por ejemplo, mayor riesgo en extremos de edad) mediante transformaciones o segmentaciones apropiadas.

Las variables `installment_rate`, `residence_since`, `existing_credits` y `num_dependents` muestran comportamientos discretos con alta concentración en pocas categorías. En particular, la mayoría de los clientes tiene entre 1 y 2 créditos y un número reducido de dependientes. Estos resultados sugieren que dichas variables pueden aportar información específica sobre estabilidad y nivel de endeudamiento, aunque su poder explicativo podría depender de interacciones con el monto solicitado, el plazo o las condiciones de empleo.

Cuadro I
RESUMEN DEL ANÁLISIS EXPLORATORIO DE LAS VARIABLES PRINCIPALES

Variable	Tipo	Comportamiento observado	Implicaciones para el modelo
credit_amount	Numérica	Sesgo marcado a la derecha; pocos créditos de monto alto.	Transformación (p.ej. log) o winsorización para reducir efecto de outliers.
duration	Numérica (ordinal)	Plazos discretos (12, 24, 36, 48, etc.).	Tratar como ordinal; posible agrupación supervisada según riesgo.
age	Numérica	Unimodal, centrada en 30–40 años, con cola hacia edades altas.	Revisar relación no lineal; considerar bins o términos no lineales.
installment_rate	Ordinal discreta	Concentración en pocas categorías (1–4).	Usar como ordinal; buscar tendencia monótona con el riesgo.
residence_since	Ordinal discreta	Mayor permanencia en algunas categorías; indicador de estabilidad.	Mantener como ordinal; evaluar asociación con incumplimiento.
existing_credits	Discreta	Mayoría con 1–2 créditos vigentes.	Captura endeudamiento previo; usar como categórica discreta.
num_dependents	Discreta	Muy concentrada en un solo valor.	Baja variabilidad; posible aporte sólo en interacciones.

V-A2. *Variables categóricas:* En el caso de las variables categóricas se cuantifica la asociación con la variable objetivo mediante Cramer's V. Los resultados se presentan en el Cuadro II. Se evidencia que `checking_status` y `credit_history` exhiben los valores más altos de asociación, lo que confirma su relevancia como predictores del perfil de riesgo del solicitante. Variables como `savings`, `purpose` y `property` muestran una asociación moderada, sugerente de información complementaria sobre liquidez, destino del crédito y garantías.

Por otro lado, variables como `telephone` y `job` presentan valores de Cramer's V cercanos a cero, lo que indica baja capacidad discriminante en este conjunto de datos; su inclusión en el modelo final deberá ser cuidadosamente evaluada mediante criterios de información y estabilidad. En conjunto, el análisis respalda la consolidación adecuada de las categorías (por ejemplo, en `checking_status`) y aporta evidencias iniciales para una selección de variables guiada por información empírica.

Cuadro II
ASOCIACIÓN ENTRE VARIABLES CATEGÓRICAS Y LA VARIABLE OBJETIVO (CRAMER)

Variable	Cramer's V
<code>checking_status</code>	0.348
<code>credit_history</code>	0.240
<code>savings</code>	0.179
<code>purpose</code>	0.156
<code>property</code>	0.144
<code>housing</code>	0.127
<code>employment</code>	0.120
<code>other_installment_plans</code>	0.104
<code>personal_status</code>	0.081
<code>foreign_worker</code>	0.069
<code>other_debtors</code>	0.068
<code>telephone</code>	0.013
<code>job</code>	0.000

En el análisis exploratorio identificamos la presencia de outliers en varias variables numéricas, especialmente en `credit_amount` y `duration`. Estos valores atípicos representan clientes con montos de crédito más altos o plazos inusualmente extendidos, lo cual es completamente normal dentro de un proceso crediticio real, donde existen perfiles de riesgo y montos muy heterogéneos. Es decir, aunque se detectaron outliers, estos reflejan variabilidad natural del negocio y no representan un problema, ni ameritan ser eliminados ni transformados. En la figura 3 se puede observar el histograma de las variables del data set bivariado.

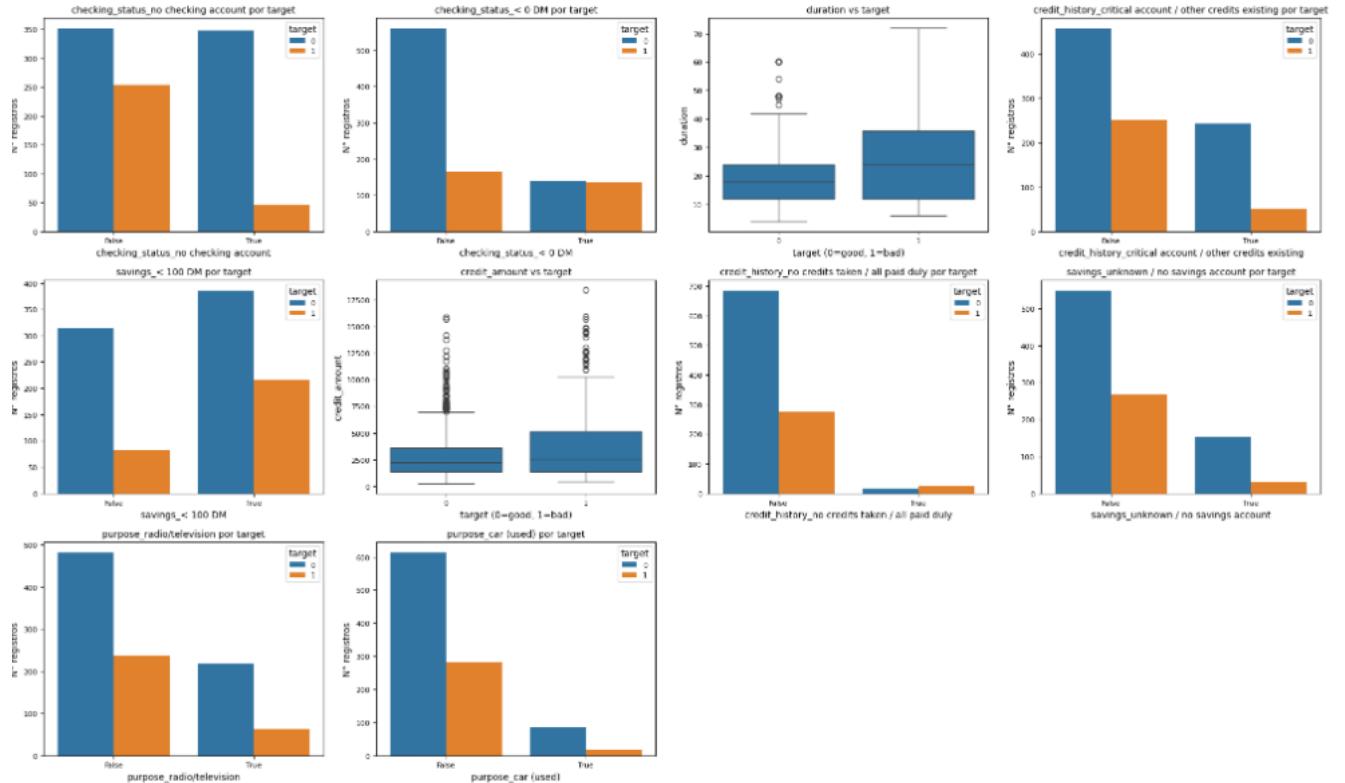


Figura 3. Histograma de Variables

VI. MODELOS DE REFERENCIA Y EXPERIMENTOS

Para determinar el mejor modelo predictivo y el que se recomendaría a la industria en el ejercicio profesional de otorgamiento de crédito se valoraron los modelos a continuación obteniendo los siguientes resultados:

VI-A. Resultado Comparativo de los modelos evaluados

La regresión logística se adopta como modelo de referencia por su interpretabilidad y amplio uso en riesgo de crédito. El ajuste realizado muestra un desempeño consistente con la estructura del conjunto de datos, manteniendo un compromiso razonable entre la correcta clasificación de clientes cumplidos y la detección de posibles incumplidores. La aplicación de regularización Lasso no condujo a la eliminación total de coeficientes, lo que indica que la mayor parte de las variables incluidas aporta alguna información explicativa, aunque con pesos diferenciados.

El comportamiento de la matriz de confusión asociada evidencia que el modelo logra captar una fracción relevante de los eventos de incumplimiento, pero conserva un nivel no despreciable de falsos negativos, propio del desbalance de clases observado en el conjunto. En un contexto operativo, este resultado implica la necesidad de calibrar umbrales de decisión y costos de error, privilegiando políticas que penalicen en mayor medida la clasificación errónea de clientes riesgosos, manteniendo al mismo tiempo una tasa de aprobación atractiva para la entidad.

VI-B. Árbol de decisión

El modelo de árbol de decisión permite capturar interacciones y relaciones no lineales entre las variables explicativas y el estado de pago, ofreciendo reglas explícitas que facilitan la interpretación por parte de las áreas de riesgo y negocio. La matriz de confusión presentada en el Cuadro ?? muestra que el árbol clasifica correctamente un número importante de clientes sin incumplimiento (verdaderos negativos), pero mantiene también una proporción relevante de falsos negativos (clientes en incumplimiento clasificados como buenos) y falsos positivos.

A partir de los conteos observados (157 verdaderos negativos, 39 verdaderos positivos, 53 falsos positivos y 51 falsos negativos), se infiere que el modelo posee una sensibilidad moderada frente a la clase de incumplimiento y una

	Modelo	Accuracy	Precision	Recall	F1	AUC
0	Reg. Logística Balanceada	0.716700	0.518800	0.766700	0.618800	0.806200
1	Reg. Logística SMOTE	0.740000	0.548400	0.755600	0.635500	0.794700
2	Reg. Log. Bal. Opt. ($\alpha=0.59$)	0.776700	0.611700	0.700000	0.652800	0.806200
3	Random Forest	0.730000	0.541300	0.655600	0.593000	0.774800
4	XGBoost Bal. Opt. ($\alpha=0.48$)	0.743300	0.565700	0.622200	0.592600	0.752200
5	CatBoost	0.723300	0.534000	0.611100	0.569900	0.765500
6	XGBoost Balanceado	0.740000	0.562500	0.600000	0.580600	0.752200
7	LightGBM	0.713300	0.519600	0.588900	0.552100	0.763700
8	Ridge (L2)	0.776700	0.666700	0.511100	0.578600	0.802600
9	Reg. Logística	0.776700	0.666700	0.511100	0.578600	0.802600
10	Gradient Boosting	0.763300	0.633800	0.500000	0.559000	0.783200
11	Lasso (L1)	0.773300	0.661800	0.500000	0.569600	0.802300
12	XGBoost	0.733300	0.567600	0.466700	0.512200	0.757400
13	Árbol de Decisión	0.726700	0.560600	0.411100	0.474400	0.745700

Figura 4. Comparación de los resultados obtenidos por modelo

especificidad más elevada para la clase cumplida. Este patrón refleja un sesgo hacia la conservación de aprobaciones seguras, a costa de no identificar todos los clientes de alto riesgo. En un escenario regulado, dicho comportamiento obliga a considerar ajustes adicionales: poda del árbol, reponderación de clases o combinación con otros modelos base, de forma que se reduzca la probabilidad de aceptar solicitantes con alta probabilidad de mora sin deteriorar excesivamente la tasa de aprobación.

Comparado con la regresión logística, el árbol ofrece mayor transparencia a nivel de reglas de decisión, pero no mejora de forma sustantiva la capacidad discriminante global. Por ello, se plantea su uso como modelo complementario, ya sea en esquemas de comité de modelos o como insumo para la generación de reglas de negocio interpretables derivadas de patrones detectados en los datos.

En la figura 4 se pueden observar las métricas en los modelos evaluados en busca del modelo más apropiado para el análisis de riesgo de crédito con base en los datos que se obtuvieron para el análisis. Desde el punto de vista del negocio crediticio, el error más costoso es un falso negativo; es decir, un cliente realmente "malo" que el modelo clasifica como "bueno" por tanto, sería objeto de crédito. Por esta razón, la métrica prioritaria utilizada para seleccionar los modelos fue el recall de la clase "malo".

Un valor alto de recall en la clase malo implica que el modelo deja escapar pocos clientes riesgosos, lo que se traduce en menor probabilidad de pérdidas financieras. Para interpretarlo con mayor claridad, el juicio experto, clasifica el recall en tres niveles basado en su capacidad de detección así:

- **Bajo:** entre 0.00 y 0.60. El modelo pierde la mayoría de los positivos.
- **Medio:** entre 0.61 y 0.70. El modelo detecta una proporción aceptable.
- **Alto:** entre 0.71 y 1.00. El modelo identifica casi todos los positivos.

En resumen, la decisión de priorizar el recall de la clase "malo" responde a la necesidad de minimizar falsos negativos y proteger la calidad de la cartera de crédito, lo cual es coherente con las buenas prácticas de modelación de riesgo en el sector financiero.

En conclusión, el modelo de regresión logístico balanceado es el de mejor comportamiento con un recall de 0.766700 final.

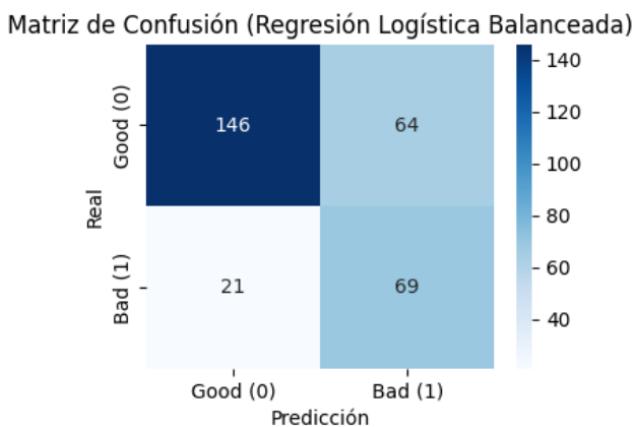


Figura 5. Matriz de confusión en el modelo de mejor rendimiento

VI-C. Rendimiento en los modelos - Mejores Métricas

En la figura 5 se observa la matriz de confusión del modelo de mejor rendimiento.

VII. CONCLUSIONES

1) Pertinencia de los predictores. El análisis exploratorio confirmó la relevancia de variables de liquidez y comportamiento (`checking_status`, `credit_history`, `savings`) como determinantes del perfil de riesgo. En variables numéricas, `credit_amount` y `duration` requieren tratamiento de escala (p.ej., `log1p`) o winsorización para mejorar la estabilidad del ajuste.

2) Manejo del desbalance. La clase de incumplimiento presenta baja incidencia, por lo que se privilegió la sensibilidad (recall) de la clase “mala” como criterio operativo central. Este enfoque es coherente con la gestión prudencial del riesgo, al disminuir la probabilidad de aceptar solicitantes riesgosos.

3) Desempeño de modelos base. La regresión logística mostró un compromiso favorable entre interpretabilidad y desempeño, con mejor sensibilidad que el árbol de decisión en las condiciones evaluadas. El árbol aportó reglas transparentes, útiles para auditoría y soporte a políticas, pero con menor capacidad discriminante global.

4) Calibración y estabilidad. Se recomienda documentar formalmente el efecto de las transformaciones (`log`/winsorización) sobre calibración (Brier) y estabilidad en el tiempo (PSI/monitoreo de drift), a fin de garantizar consistencia entre períodos y segmentos.

5) Gobernanza del modelo. Para un despliegue regulado, se sugiere incorporar: (i) *class weights* o remuestreo conservador, (ii) validación cruzada estratificada, (iii) definición de umbrales por política (*cutoffs*) con matrices de costo, y (iv) plan de monitoreo (AUC/KS/Brier/PSI) y recalibración periódica.

6) Recomendación técnica. Con base en los resultados, el *baseline* recomendado es una regresión logística penalizada (L1/L2) con *class weights*, transformaciones parciales (`log1p` y winsorización de colas cuando aplique), y *binning* monotónico en predictores ordinales. El árbol de decisión se propone como complemento para reglas operativas y explicabilidad.

7) Trabajo futuro. Explorar modelos de ensamble (p.ej., Gradient Boosting/LightGBM) con validación robusta y calibración post-hoc (Platt/Isotónica); evaluar *scorecards* con WOE/IV para trazabilidad; e integrar un tablero de monitoreo con alertas de drift y estabilidad por segmento.

REFERENCIAS

- [1] N. Siddiqi, *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*, 2nd ed. Wiley, 2017.
- [2] Superintendencia Financiera de Colombia, “Capítulo xxxi: Sistema integral de administración de riesgos (siar),” <https://www.superfinanciera.gov.co/buscar/?q=siartk=83b452e37087a9b5a07d68ede373a9bd>, Superintendencia Financiera de Colombia, Bogotá, Colombia, Circular Externa NÚMERO — Parte X, Título X, YYYY, consultado el 2025-10-19.
- [3] A. F. H. Sarango, A. P. M. Yacelga, K. H. G. Aguirre, J. N. R. Holguín, and A. K. M. Nieto, *Riesgo Crediticio: Aplicaciones Vanguardistas de Modelos Algorítmicos y Estadísticos en Cooperativas*. Know Press, 2025.
- [4] R. Salas, “Redes neuronales artificiales,” *Universidad de Valparaíso. Departamento de Computación*, vol. 1, no. 1, pp. 1–7, 2004.
- [5] J. G. G. Ojeda and P. Mahnic, “Determinación de algoritmos de clasificación óptimos para la evaluación de riesgo crediticio.”

- [6] E. G. Castañeda Luza, “Propuesta de un modelo logit para evaluar el riesgo crediticio en empresas financieras: caso de la financiera proempresa periodo 2017,” 2020.
- [7] M. S. Valenzuela Sánchez, “Predicción del riesgo crediticio en clientes del sector retail mediante redes neuronales: caso de estudio de la empresa credicorp,” Master’s thesis, Quito: Universidad de las Américas, 2025, 2025.
- [8] C. Zuniga and N. Abgar, “Breve aproximación a la técnica de árbol de decisiones,” *Recuperado de https://niefcz. files*, 2011.
- [9] U. Icesi, “Asum-dm: Operate & optimize,” <https://i2t.icesi.edu.co/ASUM-DMExternal/cognos.external.asum - DMTeaser/deliveryprocesses/ASUM - DM8A5C87D5.html>, 2024, consultado el 19 de octubre de 2025.[Online]. Available : <https://i2t.icesi.edu.co/ASUM - DMExternal/cognos.external.asum - DMTeaser/deliveryprocesses/ASUM - DM8A5C87D5.html>